

# **AJUSTE DE CURVAS. O MÉTODO DOS MÍNIMOS QUADRADOS.**

**CASO DISCRETO**

**Profa. Dra. Fernanda Paula Barbosa Pola**

# SUMÁRIO

- Introdução e contextualização;
- Objetivos;
- Ajuste de Curvas : O Método dos Mínimos Quadrados
  - Caso discreto
    - Ajuste linear - Regressão linear
    - Ajuste Polinomial
- Considerações finais;
- Referências.

# INTRODUÇÃO E CONTEXTUALIZAÇÃO

- Em geral, experimentos geram uma **gama de dados** que devem ser analisados para a criação de um **modelo**.
- Obter uma **função** matemática que **represente** (ou que ajuste) os dados permite fazer simulações do processo de forma confiável, reduzindo assim repetições de experimentos que podem ter um **custo alto**.

# INTRODUÇÃO E CONTEXTUALIZAÇÃO

- Em geral usa-se aproximações de funções nas seguintes situações:
  - Quando se deseja extrapolar ou fazer previsões em regiões fora do intervalo considerado;
  - Quando os dados tabelados são resultados de experimentos, onde erros na obtenção destes resultados podem influenciar a sua qualidade;
  - Quando deseja-se substituir uma função conhecida  $f(x)$  por outra função  $g(x)$  que facilite cálculos como derivadas e integrais.

# OBJETIVOS


- O objetivo é obter uma função que seja uma “boa aproximação” e que permita **extrapolações** com alguma margem de segurança.
- A escolha das funções pode ser feita **observando o gráfico** dos pontos tabelados, baseando-se em **fundamentos teóricos** dos experimentos que forneceu a tabela ou através de uma **função já conhecida**.

# OBJETIVOS

- Os métodos utilizados buscam uma **aproximação** do que seria o **valor exato**. Dessa forma é inerente aos métodos trabalhar com a **aproximação**, levando-se em consideração os **erros e os desvios**.
- O Método dos Mínimos Quadrados é um método bastante utilizado para **ajustar** uma determinada quantidade de **pontos e aproximar funções**.

# AJUSTE DE CURVAS - INTRODUÇÃO

Graficamente, a extrapolação e o ajuste por barras de erros são vistos na figura abaixo:



# AJUSTE DE CURVAS - INTRODUÇÃO

- Temos que ajustar estas funções tabeladas por uma função que seja uma “boa aproximação” e que permita extrapolações com alguma margem de segurança.
- Dados os pontos  $(x_1, f(x_1)), (x_2, f(x_2)), \dots, (x_m, f(x_m))$  num intervalo  $[a, b]$ , devemos escolher funções  $g_1(x), g_2(x), \dots, g_n(x)$ , e constantes  $\alpha_1(x), \alpha_2(x), \dots, \alpha_n(x)$  tais que a função  $\varphi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$  se aproxime de  $f(x)$ .



# AJUSTE DE CURVAS - INTRODUÇÃO

- Este modelo é dito linear pois os coeficientes a determinar  $\alpha_1(x), \alpha_2(x), \dots, \alpha_n(x)$  aparecem linearmente.
- Note que as funções  $g_1(x), g_2(x), \dots, g_n(x)$  podem ser funções não lineares, por exemplo:  $g_1(x) = e^x, g_2(x) = (1 + x^2), \dots$

 **Problema 1** 

Como escolher as funções  $g_1(x), g_2(x), \dots, g_n(x)$  ?

# AJUSTE DE CURVAS – CASO DISCRETO

- Podemos escolher as funções

$$g_1(x), g_2(x), \dots, g_n(x)$$


observando os pontos tabelados ou a partir de conhecimentos teóricos do experimento que nos forneceu a tabela. Portanto, dada uma tabela de pontos, deve-se primeiro colocar estes pontos num gráfico cartesiano. O gráfico resultante é chamado de **diagrama de dispersão**.

# AJUSTE DE CURVAS – CASO DISCRETO

- Seja a tabela

$x$	-1.0	-0.75	-0.6	-0.5	-0.3	0	0.2	0.4	0.5	0.7	1.0
$f(x)$	2.05	1.153	0.45	0.4	0.5	0	0.2	0.6	0.512	1.2	2.05

- O diagrama de dispersão é dado por:



# AJUSTE DE CURVAS – CASO DISCRETO

- Escolhemos  $g_1(x) = x^2$  a partir da forma dos pontos no diagrama de dispersão.

- Procuramos a função que se aproxime ao máximo de  $f(x)$  que tenha a forma

$$\varphi(x) = \alpha_1 g_1(x) = \alpha x^2$$

(parábola passando pela origem)

- **PROBLEMA 2:** Qual o valor de  $\alpha$  que gera melhor ajuste da parábola?

# AJUSTE DE CURVAS – CASO CONTÍNUO

- Dada uma função  $f(x)$  contínua em  $[a,b]$  e escolhidas as funções  $g_1(x), g_2(x), \dots, g_n(x)$  todas contínuas em  $[a,b]$ , devemos determinar as constantes  $\alpha_1, \alpha_2, \dots, \alpha_n$  de modo que a função

$$\varphi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$$

se aproxime ao máximo de  $f(x)$

# AJUSTE DE CURVAS – CASO CONTÍNUO

- Tanto no caso discreto como no caso contínuo o que significa ficar mais próxima?
- Ideia: A função  $\varphi(x)$  é tal que o módulo da área sob a curva  $|\varphi(x) - f(x)|$  seja mínimo!

# O MÉTODO DOS MÍNIMOS QUADRADOS

- Objetivo: encontrar coeficientes  $\alpha_j$  tais que a função

$$\varphi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n(x) g_n(x)$$

se aproxime ao máximo de  $f(x)$

## Método dos Mínimos Quadrados

Consiste em escolher os  $\alpha_j$ 's de modo que a soma dos quadrados dos desvios seja mínima.

# O MÉTODO DOS MÍNIMOS QUADRADOS

## CASO DISCRETO

- Desvio em  $x_k$  :  $\mathbf{d}_k = f(x_k) - \varphi(x_k)$
- Se a soma dos quadrados dos desvios

$$\sum_{k=1}^m \mathbf{d}_k^2 = \sum_{k=1}^m (f(x_k) - \varphi(x_k))^2$$

é mínima, cada desvio  $\mathbf{d}_k = f(x_k) - \varphi(x_k)$  será pequeno. Assim,  $\alpha_j$ 's devem ser tais que minimizem a função

$$\mathbf{F}(\alpha_1, \alpha_2, \dots, \alpha_n) = \sum_{k=1}^m [f(x_k) - \varphi(x_k)]^2$$



# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO

- Para obter um ponto mínimo devemos encontrar os números críticos, ou seja,  $\alpha_j$ 's tais que

$$\left. \frac{\partial \mathbf{F}}{\partial \alpha_j} \right|_{(\alpha_1, \alpha_2, \dots, \alpha_n)} = 0, \quad j = 1, 2, \dots, n$$

onde

$$\mathbf{F}(\alpha_1, \alpha_2, \dots, \alpha_n) =$$

$$\sum_{k=1}^m [f(x_k) - \alpha_1 g_1(x_k) - \alpha_2 g_2(x_k) - \dots - \alpha_n g_n(x_k)]^2$$

# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO

- Calculando as derivadas

$$\left. \frac{\partial F}{\partial \alpha_j} \right|_{(\alpha_1, \alpha_2, \dots, \alpha_n)} =$$

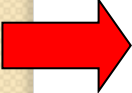
$$2 \sum_{k=1}^m [f(x_k) - \alpha_1 g_1(x_k) - \alpha_2 g_2(x_k) - \dots - \alpha_n g_n(x_k)] [-g_j(x_k)]$$

- Igualando a zero,

$$\sum_{k=1}^m [f(x_k) - \alpha_1 g_1(x_k) - \alpha_2 g_2(x_k) - \dots - \alpha_n g_n(x_k)] [g_j(x_k)] = 0, \quad j = 1, 2, \dots, n$$

# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO

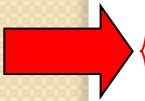
- Ou seja, temos um **sistema linear** a resolver


$$\left\{ \begin{array}{l} \sum_{k=1}^m [f(x_k) - \alpha_1 g_1(x_k) - \alpha_2 g_2(x_k) - \dots - \alpha_n g_n(x_k)][g_1(x_k)] = 0 \\ \sum_{k=1}^m [f(x_k) - \alpha_1 g_1(x_k) - \alpha_2 g_2(x_k) - \dots - \alpha_n g_n(x_k)][g_2(x_k)] = 0 \\ \vdots \\ \sum_{k=1}^m [f(x_k) - \alpha_1 g_1(x_k) - \alpha_2 g_2(x_k) - \dots - \alpha_n g_n(x_k)][g_n(x_k)] = 0 \end{array} \right.$$

# O MÉTODO DOS MÍNIMOS QUADRADOS

## CASO DISCRETO

- Reescrevendo o sistema,


$$\begin{cases} \left[ \sum_{k=1}^m g_1(x_k)g_1(x_k) \right] \alpha_1 + \dots + \left[ \sum_{k=1}^m g_n(x_k)g_1(x_k) \right] \alpha_n = \sum_{k=1}^m f(x_k)g_1(x_k) \\ \left[ \sum_{k=1}^m g_1(x_k)g_2(x_k) \right] \alpha_1 + \dots + \left[ \sum_{k=1}^m g_n(x_k)g_2(x_k) \right] \alpha_n = \sum_{k=1}^m f(x_k)g_2(x_k) \\ \vdots \\ \left[ \sum_{k=1}^m g_1(x_k)g_n(x_k) \right] \alpha_1 + \dots + \left[ \sum_{k=1}^m g_n(x_k)g_n(x_k) \right] \alpha_n = \sum_{k=1}^m f(x_k)g_n(x_k) \end{cases}$$

*Sistema linear com  $n$  equações com  $n$  incógnitas*

As equações desse sistemas linear são as chamadas **equações normais**.

# O MÉTODO DOS MÍNIMOS QUADRADOS

## CASO DISCRETO

- O sistema linear pode ser escrito na forma matricial  $A\alpha = b$ :

$$a_{11}\alpha_1 + a_{12}\alpha_2 + \dots + a_{1n}\alpha_n = b_1$$

$$a_{21}\alpha_1 + a_{22}\alpha_2 + \dots + a_{2n}\alpha_n = b_2$$

...

$$a_{n1}\alpha_1 + a_{n2}\alpha_2 + \dots + a_{nn}\alpha_n = b_n$$

- $a_{ij} = a_{ji}$ , a matriz  $A$  é simétrica;
- Se o sistema tem uma única solução, esta solução é o ponto mínimo da função  $F(\alpha_1, \alpha_2, \dots, \alpha_n)$

# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO

- **Caso Linear (Regressão Linear)**

Aproximação através de uma função linear do tipo:

$$\phi(x) = \alpha_1 x_i + \alpha_0$$

Assim o objetivo é determinar o valor de  $\alpha_0$  e  $\alpha_1$ , que minimize:

$$E = \sum_{i=1}^m [y_i - (\alpha_1 x_i + \alpha_0)]^2$$

# AJUSTE LINEAR

- Para que  $E$  seja mínimo é necessário que:

$$\frac{\partial E}{\partial \alpha_0} = 0$$

$$\frac{\partial E}{\partial \alpha_1} = 0$$

# AJUSTE LINEAR

- As equações simplificam-se nas Equações Normais

$$\alpha_0 m + \alpha_1 \sum_{i=1}^m x_i = \sum_{i=1}^m y_i$$

$$\alpha_0 \sum_{i=1}^m x_i + \alpha_1 \sum_{i=1}^m x_i^2 = \sum_{i=1}^m x_i y_i$$



# AJUSTE LINEAR

- A solução para o sistema de equações é:

$$\alpha_0 = \frac{\left(\sum_{i=1}^m x_i^2\right)\left(\sum_{i=1}^m y_i\right) - \left(\sum_{i=1}^m x_i y_i\right)\left(\sum_{i=1}^m x_i\right)}{m\left(\sum_{i=1}^m x_i^2\right) - \left(\sum_{i=1}^m x_i\right)^2}$$

$$\alpha_1 = \frac{m\left(\sum_{i=1}^m x_i y_i\right) - \left(\sum_{i=1}^m x_i\right)\left(\sum_{i=1}^m y_i\right)}{m\left(\sum_{i=1}^m x_i^2\right) - \left(\sum_{i=1}^m x_i\right)^2}$$

# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO

- **Caso Linear (Regressão Linear)**

*Exemplo 1:* Considerando os dados da Tabela 1, e através do gráfico gerado, pode-se definir que tipo de curva melhor se ajusta aos dados.

**Tabela 1**

$x_i$	1	2	3	4	5	6	7	8	9	10
$y_i$	1,3	3,5	4,2	5,0	7,0	8,8	10,1	12,5	13,0	15,6

# O MÉTODO DOS MÍNIMOS QUADRADOS

## CASO DISCRETO




Diagrama de Dispersão para os dados da Tabela 1

# O MÉTODO DOS MÍNIMOS QUADRADOS

## CASO DISCRETO

- Considerando a Tabela 1, e os dados necessários para as equações normais, a Tabela 2 pode ser construída:

$i$	$x_i$	$y_i$	$x_i^2$	$x_i y_i$
1	1	1,3	1	1,3
2	2	3,5	4	7,0
3	3	4,2	9	12,6
4	4	5,0	16	20,0
5	5	7,0	25	35,0
6	6	8,8	36	52,8
7	7	10,1	49	70,7
8	8	12,5	64	100,0
9	9	13,0	81	117,0
10	10	15,6	100	156,0
$\Sigma$	<b>55</b>	<b>81</b>	<b>385</b>	<b>572,4</b>

# O MÉTODO DOS MÍNIMOS QUADRADOS

## CASO DISCRETO

- Considerando os dados da Tabela 2, os parâmetros  $\alpha_0$  e  $\alpha_1$  podem ser calculados como:

$$\alpha_0 = -0,360$$


$$\alpha_1 = 1,538$$

- Assim a reta a ser ajustada é determinada por:

$$y = 1,538x - 0,360$$

# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO

- Pode-se observar o ajuste através da reta:



Ajuste Linear

# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO


- **Caso Linear (Regressão Linear)**

*Exemplo 2:* Encontre a reta de mínimos quadrados que melhor se ajusta aos pontos (2,1), (5,2), (7,3), (8,3).

Calculemos para  $g_1(x) = 1$  e  $g_2(x) = x$ .

$$\sum_{k=1}^4 1_k \cdot 1_k \alpha_1 + \sum_{k=1}^4 x_k \cdot 1_k \alpha_2 = \sum_{k=1}^4 f(x_k) \cdot 1_k$$

$$\sum_{k=1}^4 x_k \cdot 1_k \alpha_1 + \sum_{k=1}^4 x_k \cdot x_k \alpha_2 = \sum_{k=1}^4 f(x_k) \cdot x_k$$



$$(1 + 1 + 1 + 1)\alpha_1 + (2 + 5 + 7 + 8)\alpha_2 = (1 + 2 + 3 + 3)$$


$$(2 + 5 + 7 + 8)\alpha_1 + (2^2 + 5^2 + 7^2 + 8^2)\alpha_2 = (2 \cdot 1 + 5 \cdot 2 + 7 \cdot 3 + 8 \cdot 3)$$

# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO

- Logo 
$$\begin{bmatrix} 4 & 22 \\ 22 & 142 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 9 \\ 57 \end{bmatrix}$$

$$\begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 4 & 22 \\ 22 & 142 \end{bmatrix}^{-1} \begin{bmatrix} 9 \\ 57 \end{bmatrix} = \frac{1}{84} \begin{bmatrix} 142 & -22 \\ -22 & 4 \end{bmatrix} \begin{bmatrix} 9 \\ 57 \end{bmatrix} = \begin{bmatrix} 2/7 \\ 5/14 \end{bmatrix}$$

$$\varphi(x) = \frac{2}{7} + \frac{5}{14}x$$





# O MÉTODO DOS MÍNIMOS QUADRADOS

- **Caso Polinomial**

O processo usado para o ajuste linear pode ser estendido para ajuste polinomial.

Assim, uma função polinomial de grau  $n$  é dada por:

$$P_n(x) = \alpha_n x^n + \alpha_{n-1} x^{n-1} + \cdots + \alpha_1 x + \alpha_0$$

O objetivo é minimizar o erro:

$$E = \sum_{i=1}^m [y_i - P_n(x_i)]^2$$

# O MÉTODO DOS MÍNIMOS QUADRADOS

Como no caso linear, para que  $E$  seja minimizado é necessário que:

$$\frac{\partial E}{\partial \alpha_j}(\alpha_0, \alpha_1, \dots, \alpha_n) = 0 \quad \text{para cada } j = 0, 1, \dots, n.$$

Isto fornece as  $n+1$  equações normais nas  $n+1$  incógnitas  $\alpha_j$ :

$$\sum_{k=0}^n \alpha_k \sum_{i=1}^m x_i^{j+k} = \sum_{i=1}^m y_i x_i^j \quad \text{para cada } j = 0, 1, \dots, n.$$

# O MÉTODO DOS MÍNIMOS QUADRADOS

$$\alpha_0 m + \alpha_1 \sum_{i=1}^m x_i + \alpha_2 \sum_{i=1}^m x_i^2 + \cdots + \alpha_n \sum_{i=1}^m x_i^n = \sum_{i=1}^m y_i$$

$$\alpha_0 \sum_{i=1}^m x_i + \alpha_1 \sum_{i=1}^m x_i^2 + \alpha_2 \sum_{i=1}^m x_i^3 + \cdots + \alpha_n \sum_{i=1}^m x_i^{n+1} = \sum_{i=1}^m y_i x_i$$

$$\vdots$$
$$\vdots$$

$$\alpha_0 \sum_{i=1}^m x_i^n + \alpha_1 \sum_{i=1}^m x_i^{n+1} + \alpha_2 \sum_{i=1}^m x_i^{n+2} + \cdots + \alpha_n \sum_{i=1}^m x_i^{2n} = \sum_{i=1}^m y_i x_i^n$$

# O MÉTODO DOS MÍNIMOS QUADRADOS

Ajustar os dados da Tabela 3 com um polinômio de grau dois utilizando o método dos mínimos quadrados.

**Tabela 3**

$i$	$x_i$	$y_i$
1	0,00	1,0000
2	0,25	1,2840
3	0,50	1,6487
4	0,75	2,1170
5	1,00	2,7183

# O MÉTODO DOS MÍNIMOS QUADRADOS

$i$	$x_i$	$y_i$	$x_i^2$	$x_i^3$	$x_i^4$	$x_i y_i$	$x_i^2 y_i$
1	0,00	1,0000	0,0000	0,0000	0,0000	0,0000	0,0000
2	0,25	1,2840	0,0625	0,1563	0,0039	0,3210	0,0803
3	0,50	1,6487	0,2500	0,1250	0,0625	0,8244	0,4122
4	0,75	2,1170	0,5625	0,4219	0,3164	1,5878	1,1908
5	1,00	2,7183	1,0000	1,0000	1,000	2,7183	2,7183
$\Sigma$	2,50	8,7680	1,875	1,5625	1,3828	5,4514	4,4015

# O MÉTODO DOS MÍNIMOS QUADRADOS

Para este problema,  $n = 2$ ,  $m = 5$  e as três equações normais são:

$$\left\{ \begin{array}{l} 5,0\alpha_0 + 2,5\alpha_1 + 1,875\alpha_2 = 8,7680 \\ 2,5\alpha_0 + 1,875\alpha_1 + 1,5625\alpha_2 = 5,4514 \\ 1,875\alpha_0 + 1,5625\alpha_1 + 1,3828\alpha_2 = 4,4015 \end{array} \right.$$

Resolvendo o sistema, obtêm-se:


$$\alpha_0 = 1,0051$$

$$\alpha_1 = 0,8647$$

$$\alpha_2 = 0,8432$$

# O MÉTODO DOS MÍNIMOS QUADRADOS

$$y = 1,0051 + 0,8647x + 0,8432x^2$$



O erro total

$$E = \sum_{i=1}^5 [y_i - P(x_i)]^2 = 2,74 \times 10^{-4}$$

é o mínimo que pode ser  
obtido usando um  
polinômio com grau  
máximo 2

# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO

- **Caso Polinomial**

*Exemplo 3:* Seja o conjunto de pontos:

$x$	-1.0	-0.75	-0.6	-0.5	-0.3	0	0.2	0.4	0.5	0.7	1.0
$f(x)$	2.05	1.153	0.45	0.4	0.5	0	0.2	0.6	0.512	1.2	2.05

Encontre a parábola através dos mínimos quadrados que melhor se ajusta aos pontos da tabela.

- Vimos pelo diagrama de dispersão que uma parábola pela origem seria uma boa escolha, logo seja,

$$g_1(x) = x^2 \Rightarrow \varphi(x) = \alpha_1 x^2 = \alpha x^2$$



# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO

- Logo temos uma equação dada por,

$$\left[ \sum_{k=1}^{11} g_1(x_k) g_1(x_k) \right] \alpha_1 = \sum_{k=1}^{11} f(x_k) g_1(x_k)$$

$$\Rightarrow \alpha_1 \sum_{k=1}^{11} [g_1(x_k)]^2 = \sum_{k=1}^{11} f(x_k) g_1(x_k)$$

$$\Rightarrow \alpha_1 \sum_{k=1}^{11} [(x_k)]^4 = \sum_{k=1}^{11} [(x_k)]^2 f(x_k)$$

# O MÉTODO DOS MÍNIMOS QUADRADOS CASO DISCRETO

Calculando as somas:

x	-1	-0,75	-0,6	-0,5	-0,3	0	0,2	0,4	0,5	0,7	1	somas
x2.x2	1	0,3164	0,1296	0,0625	0,0081	0	0,0016	0,0256	0,0625	0,2401	1	2,8464
f(x).x2	2,05	0,6485	0,162	0,1	0,045	0	0,008	0,096	0,128	0,588	2,05	5,8756

Nossa equação é

$$2,8464\alpha = 5,8756$$

$$\alpha = 2,0642$$

Então  $\varphi(x) = 2.0642x^2$  é a parábola que melhor se aproxima, no sentido dos quadrados mínimos, da função tabelada.

# AJUSTE NÃO-LINEAR

- Existem casos, onde o diagrama de dispersão de uma função indica que os dados devem ser ajustados por uma função não linear.
- Ocasionalmente, é apropriado supor que os dados estejam relacionados exponencialmente.
- Exemplo:  $\phi(x) = ae^{bx}$ , para  $a$  e  $b$  constantes.
- A **dificuldade** de aplicação do método dos mínimos quadrados neste caso consiste na tentativa de **minimizar o erro**.

# AJUSTE NÃO-LINEAR

- Para estes casos, um **Processo de Linearização** deve ser empregado, para que seja possível aplicar o Método dos Mínimos Quadrados.
- Neste caso, podemos proceder da seguinte forma:

# AJUSTE NÃO-LINEAR

- Caso I: **Função Exponencial**

$$\varphi(x) = y = ae^{bx}$$

- Aplicando logaritmo em ambos os lados, obtêm-se:

$$\ln(y) = \ln(ae^{bx}) = \ln(a) + bx$$

- Realizando as seguintes substituições:

- Obtêm-se:  $Y = \alpha_1 X + \alpha_0$

$$Y = \ln(y)$$

$$\alpha_0 = \ln(a)$$

$$\alpha_1 = b$$

$$X = x$$

# AJUSTE NÃO-LINEAR

- Caso II: **Função Logarítmica**

$$y = a \ln(bx)$$

- Expandindo:  $y = a \ln(b) + a \ln(x)$

- Realizando as seguintes substituições:

$$Y = y$$

$$\alpha_0 = a \ln(b)$$

$$\alpha_1 = a$$

$$X = \ln(x)$$

- Obtêm-se:  $Y = \alpha_1 X + \alpha_0$

# AJUSTE NÃO-LINEAR

- Caso III: **Função Potencial**

$$y = ax^b$$

- Aplicando logaritmo em ambos os lados:

$$\ln(y) = \ln(ax^b) = \ln(a) + \ln(x^b) = \ln(a) + b \ln(x)$$

- Realizando as seguintes substituições:

- Obtêm-se:  $Y = \alpha_1 X + \alpha_0$

$$Y = \ln(y)$$

$$\alpha_0 = \ln(a)$$

$$\alpha_1 = b$$

$$X = \ln(x)$$

# AJUSTE NÃO-LINEAR

- Caso IV: **Função Hiperbólica**

$$y = a + \frac{b}{x}$$

- Realizando as seguintes substituições:

$$\left\{ \begin{array}{l} Y = y \\ \alpha_0 = a \\ \alpha_1 = b \\ X = x^{-1} \end{array} \right.$$

- Obtêm-se:  $Y = \alpha_1 X + \alpha_0$



# AJUSTE NÃO-LINEAR

- Usa-se as equações de Ajuste Linear para obter  $\alpha_0$  e  $\alpha_1$

$$\alpha_0 m + \alpha_1 \sum_{i=1}^m x_i = \sum_{i=1}^m y_i$$

$$\alpha_0 \sum_{i=1}^m x_i + \alpha_1 \sum_{i=1}^m x_i^2 = \sum_{i=1}^m x_i y_i$$

# LEMBRE-SE!

- Após aplicar o método dos mínimos quadrados, é preciso fazer as substituições necessárias para encontrar os parâmetros a e b da função de aproximação original.

# IMPORTANTE

- Observe que os parâmetros assim obtidos não são ótimos dentro do critério dos quadrados mínimos, porque estamos ajustando o problema linearizado e não o problema original.

# AJUSTE NÃO-LINEAR

- Exemplo:


Encontrar uma função que se ajusta aos valores da tabela abaixo:

$x$	$y$
-1,0	36,547
-0,7	17,267
-0,4	8,155
-0,1	3,852
0,2	1,82
0,5	0,86
0,8	0,406
1,0	0,246

# AJUSTE NÃO-LINEAR

$$\left\{ \begin{array}{l} Y = \ln y \\ \alpha_0 = \ln(a) \\ \alpha_1 = -b \end{array} \right.$$

$$y = ae^{-bx}$$



# AJUSTE NÃO-LINEAR

- Como o ajuste será realizado por uma função exponencial é necessário calcular:  $Y = \ln y$

$i$	$x$	$y$	$Y = \ln(y)$	$x_i^2$	$x_i Y_i$
1	-1,0	36,547	3,599	1,00	-3,599
2	-0,7	17,264	2,849	0,49	-1,994
3	-0,4	8,155	2,099	0,16	-0,839
4	-0,1	3,852	1,349	0,01	-0,135
5	0,2	1,820	0,599	0,04	0,120
6	0,5	0,860	-0,151	0,25	-0,075
7	0,8	0,406	-0,901	0,64	-0,721
8	1,0	0,246	-1,402	1,00	-1,402
$\Sigma$	0,3	69,15	8,041	3,59	-8,645

# AJUSTE NÃO-LINEAR

$$\alpha_0 = 1,099$$

$$\alpha_1 = -2,5$$

$$\alpha_0 = \ln(a)$$

$$\alpha_1 = -b$$

$$a = 3,001$$

$$b = 2,5$$

$$y = 3,001e^{-2,5x}$$

# TESTE DE ALINHAMENTO

- Uma vez escolhida uma função não linear em  $a, b, \dots$  para ajustar uma função, uma forma de verificar se a escolha foi razoável é aplicar o **Teste de Alinhamento**



# TESTE DE ALINHAMENTO

- Fazer a linearização da função não linear escolhida;
- Fazer o diagrama de dispersão dos novos dados;
- Se os pontos do diagrama estiverem alinhados, isto significará que a função linear foi uma “boa escolha”.

# TESTE DE ALINHAMENTO

Gráfico de  $x$  versus  $Y = \ln y$

$i$	$x$	$y$	$Y = \ln(y)$
1	-1	36,547	3,599
2	-0,7	17,264	2,849
3	-0,4	8,155	2,099
4	-0,1	3,852	1,349
5	0,2	1,820	0,599
6	0,5	0,860	-0,151
7	0,8	0,406	-0,901
8	1	0,246	-1,402
$\Sigma$	0,3	69,15	8,041

# TESTE DE ALINHAMENTO




Diagrama de dispersão dos novos dados ( $Y = \ln y$ ).

# AJUSTE NÃO-LINEAR

- Exemplo:

- Usando o Método dos Mínimos Quadrados, ajustar uma curva do tipo  $s = q t^p$  aos dados abaixo:

$t$	2,2	2,7	3,5	4,1
$s$	65	60	53	50

- Qual o valor de  $s$  quando  $t = 4,5$ ?
- Qual o valor de  $t$  quando  $s = 40$ ?

# AJUSTE NÃO-LINEAR

- Caso III: **Função Potencial**

$$s = qt^p$$

- Aplicando logaritmo em ambos os lados:

$$\log s = \log q + p \log t$$

- Realizando as seguintes substituições:

- Obtêm-se:  $Y = \alpha_1 X + \alpha_0$

$$Y = \log s$$

$$\alpha_0 = \log q$$

$$\alpha_1 = p$$

$$X = \log t$$

# AJUSTE NÃO-LINEAR

□ Temos então:

$i$	$t$	$s$	$X_i$	$Y_i$	$X_i^2$	$X_i Y_i$
1	2,2	65	0,3424	1,8129	0,1172	0,6207
2	2,7	60	0,4314	1,7782	0,1861	0,7671
3	3,5	53	0,5441	1,7243	0,2960	0,9382
4	4,1	50	0,6128	1,6990	0,3755	1,0411
$\Sigma$			<b>1,9307</b>	<b>7,0144</b>	<b>0,9748</b>	<b>3,3671</b>

# AJUSTE NÃO-LINEAR

$$\begin{cases} 4\alpha_0 + 1,9307\alpha_1 = 7,0144 \\ 1,9307\alpha_0 + 0,9748\alpha_1 = 3,3671 \end{cases}$$

$$\alpha_0 = 1,963$$

$$\alpha_1 = -0,434$$

$$\alpha_0 = \log q$$

$$\alpha_1 = p$$

$$q = 91,83$$

$$p = -0,434$$

$$s = 91,83 t^{-0,434}$$

# AJUSTE NÃO-LINEAR

□ Se:

$$s = 91,83t^{-0,434}$$

□ então, para  $t = 4,5$ ;  $s \approx 48$ , e para  $s = 40$ ;  $t \approx 6,8$ .



# CONSIDERAÇÕES FINAIS

- O ajuste de curvas é uma boa estratégia para avaliar a natureza de uma massa de dados;
- Ele mostra qual o comportamento da tabela, ou seja, ele busca por uma curva contínua, conhecida, que possa representar o comportamento da tabela.

# REFERÊNCIAS

- M.A. Gomes Ruggiero, V. L. da Rocha Lopes. Cálculo Numérico - Aspectos Teóricos e Computacionais, 2ª edição, Editora Pearson, 1997.
- M.C. Cunha. Métodos Numéricos. 2ª edição, Editora da Unicamp, 2000.
- N.B. Franco. Cálculo Numérico. Pearson Prentice Hall, 2007.
- Richard L. Burden e J. Douglas Faires, Análise Numérica, Cengage Learning, Tradução da 8. Ed. Americana, 2008